


VAE como extractor de características relevantes en imágenes médicas

— Ana Paula Morresi - Licenciatura en Física —
Protecto Final - APBF


Imágenes MRI Cardiacas



Problema a evaluar: Clasificación Patologías



Variational Autoencoder (VAE)




Preprocesamiento:

- **Resampleo:** se redimensionan las imágenes (interpolación) para que la distancia entre pixel sea (1.5, 1.5, 10) mm.
- **Limpieza intensidades:** clip a percentil 1 y 99, lleva imágenes a valores [0,1].
- **Crop:** se hace un corte central o ampliación (padding con ceros) para que sean todas de 224 x 224 x 10 pixels.
- **Normalización:** se normaliza a media 0 y desvío 1 por slice.

Arquitecturas:

VAE3D (v1) — 532,865 params



Encoder
Latente z
Decoder


VAE3DDeep (deep) — 607,361 params




Encoder
Latente z
Decoder

Arquitecturas clasificadores:


Conv+MLP — 223,588 params



Clasificadores sobre espacio latente (lat_ch=64, ED+ES concatenados)
MLP — 10,468 params



Flat MLP — 6,439,492 params



La loss total es el negativo del ELBO:

$$\mathcal{L} = \underbrace{\frac{1}{N} \sum_{i=1}^N (x_i - \hat{x}_i)^2}_{\text{MSE (reconstrucción)}} + \beta \cdot \underbrace{\left(-\frac{1}{2} \sum_{j=1}^D (1 + \log \sigma_j^2 - \mu_j^2 - \sigma_j^2) \right)}_{\text{KL divergence}}$$

donde $D = \text{lat} \times 14 \times 14 \times 1$ es la dimensión total del latente.

MSE

$$\mathcal{L}_{\text{MSE}} = \frac{1}{N} \sum_{i=1}^N (x_i - \hat{x}_i)^2$$

- x_i : vóxel i de la imagen original
- $\hat{x}_i$: vóxel i de la imagen reconstruida
- N : número total de vóxeles del batch

SSIM

$$\text{SSIM}(x, \hat{x}) = \frac{(2\mu_x\mu_{\hat{x}} + C_1)(2\sigma_{x\hat{x}} + C_2)}{(\mu_x^2 + \mu_{\hat{x}}^2 + C_1)(\sigma_x^2 + \sigma_{\hat{x}}^2 + C_2)}$$

- $\mu_x, \mu_{\hat{x}}$: medias locales de x y $\hat{x}$ (ventana gaussiana)
- $\sigma_x^2, \sigma_{\hat{x}}^2$: varianzas locales
- $\sigma_{x\hat{x}}$: covarianza local entre x y $\hat{x}$
- $C_1 = 0.01^2$, $C_2 = 0.03^2$: constantes de estabilidad numérica

El término en la loss es $\mathcal{L}_{\text{SSIM}} = 1 - \text{SSIM}(x, \hat{x})$, ya que $\text{SSIM}=1$ es perfecto.


Función Loss:

$$\mathcal{L} = \mathcal{L}_{\text{MSE}} + w_{\text{SSIM}} \mathcal{L}_{\text{SSIM}} + \beta \mathcal{L}_{\text{KL}}$$


Para entrenar hacemos
split en train-val-test
(60-20-20)

Resultados:

mse/ssim - ch=16




mse - ch=64



reconstrucción
mejor de detalles


mse - ch=64 - deep




reconstrucción más
suave

Arquitecturas clasificadores:


Conv+MLP — 223,588 params



Clasificadores sobre espacio latente (lat_ch=64, ED+ES concatenados)
MLP — 10,468 params




Flat MLP — 6,439,492 params




Arquitecturas clasificadores:


Conv+MLP — 223,588 params




Clasificadores sobre espacio latente (lat_ch=64, ED+ES concatenados)
MLP — 10,468 params



Flat MLP — 6,439,492 params



Arquitecturas clasificadores:




Resultados:

Macro	mse-ch=16	ssim-ch=16	mse-ch=64	mse-ch=64-deep
F1-Score	0.509	0.508	0.483	0.521
AUC-ROC	0.744	0.742	0.734	0.736

Resultados:


Macro	mse-ch=16	ssim-ch=16	mse-ch=64	mse-ch=64-deep
F1-Score	0.509	0.508	0.483	0.521
AUC-ROC	0.744	0.742	0.734	0.736



	RV	HCM	NOR	DCM
F1-Score	0.606	0.545	0.525	0.407
AUC-ROC	0.862	0.730	0.654	0.695
support	15	36	44	27

Resultados:


Macro	mse-ch=16	ssim-ch=16	mse-ch=64	mse-ch=64-deep
F1-Score	0.509	0.508	0.483	0.521
AUC-ROC	0.744	0.742	0.734	0.736



	RV	HCM	NOR	DCM
F1-Score	0.606	0.545	0.525	0.407
AUC-ROC	0.862	0.730	0.654	0.695
support	15	36	44	27



Resultados:

Macro	mse-ch=16	ssim-ch=16	mse-ch=64	mse-ch=64-deep
F1-Score	0.509		0.483	0.521
AUC-ROC	0.744		0.734	0.736




		HCM	NOR	DCM
		0.545	0.525	0.407
AUC-ROC	0.862	0.730	0.654	0.695
support	15	36	44	27

Modelo base supervisado:






Encoder + Clasificador (baseline supervisado)
Encoder trainable — sin decoder — loss: CrossEntropy




	supervisado	VAE+clasificación
Macro F1-Score	0.471	0.521

Modelo base supervisado:



Encoder + Clasificador (baseline supervisado)
Encoder trainable — sin decoder — loss: CrossEntropy



	supervisado	VAE+clasificación
Macro F1-Score	0.471	0.521


Conclusiones:

- A pesar de obtener reconstrucciones que logran capturar la forma de las principales partes del corazón, el espacio generado no es útil para llevar a cabo tareas específicas como clasificación de patologías.
- Para este caso una mejor reconstrucción no implicaría necesariamente una mejora en la clasificación.
- Probe con un modelo MedVAE (modelo muuuy grande) que reconstruye casi perfecto mis imágenes pero el espacio latente sigue sin ser útil para clasificación.
- Otros enfoques como buscar hacer segmentación de las imágenes facilitan la clasificación posterior, esto implica tener la suficiente cantidad de imágenes segmentadas para entrenar.
- Usar métodos de contrastive learning podrían ayudar a dar mejores resultados, pero si tomamos clases positivas y negativas necesitamos etiquetas.
- En particular métodos como DINO me han funcionado bastante mejor, donde compramos una imagen con “diferentes vistas” de la misma de forma más compleja.

MUCHAS GRACIAS

Modelo VIT-DINOv3+LORA+SSL:

```
DinoMLP in_dim=768 hidden=(256, 64) params=213,572
DinoMLP(
  (net): Sequential(
    (0): Linear(in_features=768, out_features=256, bias=True)
    (1): ReLU(inplace=True)
    (2): Dropout(p=0.3, inplace=False)
    (3): Linear(in_features=256, out_features=64, bias=True)
    (4): ReLU(inplace=True)
    (5): Dropout(p=0.3, inplace=False)
    (6): Linear(in_features=64, out_features=4, bias=True)
  )
)
```



— Test results —

	precision	recall	f1-score	support
NOR	0.72	0.75	0.73	44
DCM	0.73	0.70	0.72	27
HCM	0.76	0.69	0.72	36
RV	0.59	0.67	0.62	15
accuracy			0.71	122
macro avg	0.70	0.70	0.70	122
weighted avg	0.72	0.71	0.71	122

AUC-ROC por clase:

NOR: 0.8730

DCM: 0.9267

HCM: 0.9050

RV: 0.9246

AUC-ROC macro: 0.9073

AUC-ROC weighted: 0.9007

Extras:

